

Anomaly Detection in IoT Temperature Data

Experimental Comparison — Isolation Forest

IoT
ML

Exp1

Raw Data
(no scaling)

Exp2

Raw Data
+ StandardScaler

Exp3

5 Features
+ RobustScaler ✓

Exp4

2 Features
(Subset)

The Core Problem



Θερμική Αδράνεια (που συζητήσαμε)

Η εσωτερική θερμοκρασία μένει σταθερή (η με μικρές αλλαγές ενώ η εξωτερική ανεβοκατεβαίνει απότομα. Τα Raw data δείχνουν μεγάλο κενό – αλλά αυτό είναι φυσιολογικό φαινόμενο , όχι ανωμαλία.



Ανεπεξέργαστα δεδομένα

Feeding field1 + field2 directly → IsolationForest flags the temperature gap as anomalous, penalizing good insulation.



Στόχος πραγματικής “ανωμαλίας”

Sudden, unnatural DROP in indoor temp — e.g. a window opened in winter. The model must learn to detect dynamic changes, not static differences.

Λύση: Η επεξεργασία χαρακτηριστικών καταγράφει τον ΡΥΘΜΟ ΜΕΤΑΒΟΛΗΣ, όχι τις απόλυτες τιμές → το μοντέλο μαθαίνει τη δυναμική, όχι τις μεταβολές

Πειραματική Διάταξη

Πειραματική Διάταξη & Παράμετροι

Algorithm: Isolation Forest

n_estimators: 200 trees

contamination: 0.04 (4%)

max_samples: auto

random_state: 42 (reproducible)

Scaler: RobustScaler (median/IQR)

Δεδομένα (Dataset)

Source: Arduino MKR WiFi 1010 + Oplà

Raw records: 4,072 (≈1 min interval)

Resampled: 429 (10-min interval)

Period: 05/05 – 08/05/2026

field1: Indoor temp (HTS221 sensor)

field2: Outdoor temp (OpenWeatherMap)

Exp1

field1 + field2
No scaling

Exp2

field1 + field2
StandardScaler (z-score)

Exp3

5 engineered features
RobustScaler ★

Exp4

roc_10min + delta_gap
RobustScaler

Feature Engineering — Exp3

Why we replaced raw values with derived features:

roc_10min

$$T[t] - T[t-1]$$

Η μεταβολή της εσωτερικής θερμοκρασίας στο τελευταίο 10λεπτο. Πιάνει αμέσως το σοκ.(1-step)

roc_30min

$$T[t] - T[t-3]$$

Η μεταβολή σε βάθος 30 λεπτών. Φιλτράρει τον τυχαίο θόρυβο του αισθητήρα.

rolling_std_30

$$\text{std}(T[t], T[t-1], T[t-2])$$

Κυλιόμενη τυπική απόκλιση 30 λεπτών. Δείχνει αν η θερμοκρασία έχει αστάθεια.

delta_thermal_gap

$$(T_{in}-T_{out})[t] - (T_{in}-T_{out})[t-1]$$

Πόσο γρήγορα αλλάζει η διαφορά μέσα-έξω. Ιδανικό για την παράκαμψη της μόνωσης.

acceleration

$$\text{roc}[t] - \text{roc}[t-1]$$

Δεύτερη παράγωγος. Δείχνει αν η πτώση επιταχύνεται (έναρξη γεγονότος).

Αποτελέσματα— Time Series (ανά πείραμα)

Red dots = detected anomalies | Blue = indoor | Orange = outdoor


Experiment Comparison — Isolation Forest Anomaly Detection (10-min sampling)



Κατανομή του Anomaly Score ανά Πείραμα


Row 1: histogram of scores per experiment | Row 2: scores over time (red = flagged anomaly)

Anomaly Score Distributions per Experiment



Συνολικές Μετρικές

Key metric: $\text{Score Separation} = \text{mean}(\text{normal scores}) - \text{mean}(\text{anomaly scores})$. Higher = clearer distinction.



Key Insight:

Σταθερός Αριθμός Ανωμαλιών: Λόγω του $\text{contamination}=0.04$, ο αλγόριθμος απομονώνει σε όλα τα πειράματα ακριβώς 17 σημεία (4%).

Score Separation (Μετρική Ποιότητας): Μετράει πόσο απέχει η μέση τιμή των φυσιολογικών από τις ανωμαλίες.

Υπερδιδασιασμός Απόδοσης: Από 0.129 (Raw Data) ανεβήκαμε στο 0.272 (Exp3) και 0.280 (Exp4).


Συμπέρασμα: Το Feature Engineering διπλασιάζει την ικανότητα του μοντέλου να ξεχωρίζει την ανωμαλία.

Ανάλυση Χαρακτηριστικών


Αριστερά: πόσο αποκλίνει κάθε χαρακτηριστικό στις ανωμαλίες σε σύγκριση με το φυσιολογικό / Κέντρο: ευαισθησία στη μόλυνση / Δεξιά: Συμφωνία αποτελεσμάτων Exp1 έναντι Exp3

Feature Engineering Deep-Dive


Feature Signal Strength
(anomaly mean / normal mean)



Contamination Sensitivity
(Exp3)



Score Agreement
Exp1 vs Exp3



Observations:

Ισχύς Σήματος (Signal Strength): Η κυλιόμενη τυπική απόκλιση (8.20x) και η επιτάχυνση (6.39x) έχουν την υψηλότερη απόκλιση κατά τις ανωμαλίες.

Σταθερότητα Μοντέλου: Η ανάλυση ευαισθησίας δείχνει σταθερό αριθμό ανωμαλιών στο εύρος contamination 0.03 - 0.05.

Συμφωνία Μοντέλων (Score Agreement): Το Raw μοντέλο και το προτεινόμενο μοντέλο δεν συμφωνούν σχεδόν καθόλου, επιβεβαιώνοντας ότι φιλτράραμε τους ψευδείς συναγερμούς.

Συγκριτικός Πίνακας

Experiment	Input Features	Scaler	Anomalies	Sep. Score	Assessment
Exp1	field1 + field2 (raw values)	None	17 (4.0%)	0.129	✗ Τιμωρεί τη μόνωση / Χαμηλός διαχωρισμός.
Exp2	field1 + field2 (raw values)	StandardScaler	17 (4.0%)	0.129	✗ Ίδιο αποτέλεσμα
Exp3 ★	5 engineered features	RobustScaler	17 (4.0%)	0.272	✓ Μέγιστη ευρωστία (Robustness) και πλήρης φυσική ερμηνεία.
Exp4	2 features (roc + gap)	RobustScaler	17 (4.0%)	0.280	✓ Κορυφαίος διαχωρισμός, ιδανικό για μελλοντική απλοποίηση στο Edge.

Το Exp3 επιλέχθηκε ως τελικό μοντέλο — η καλύτερη ισορροπία μεταξύ διαχωρισμού, ερμηνευσιμότητας και φυσικής σημασίας

Conclusions & Next Steps



Feature Engineering doubles model quality

Ο διαχωρισμός των σκορ (Score Separation) αυξήθηκε από 0.129 (ανεπεξέργαστα δεδομένα) σε 0.272 (με τα νέα χαρακτηριστικά).



RobustScaler outperforms StandardScaler

Χρησιμοποιεί τη διάμεσο και το ενδοτεταρτημοριακό εύρος (median/IQR) αντί για τη μέση τιμή και την τυπική απόκλιση (mean/std), με αποτέλεσμα να μην επηρεάζεται από τις ίδιες τις ανωμαλίες που ψάχνουμε, προστατεύοντας το σήμα των απότομων μεταβολών (spikes).



Isolation Forest is appropriate for this problem

Είναι μη επιβλεπόμενος (Unsupervised - δεν χρειάζεται έτοιμα ταξινομημένες ανωμαλίες). Είναι αρκετά ελαφρύς για εγκατάσταση στο Edge και παρέχει ένα συνεχές σκορ ανωμαλίας (anomaly score).

Next Steps

→ Εγκατάσταση του μοντέλου στο Arduino MKR WiFi 1010 (τοπική πρόβλεψη/inference, deep sleep, και αποστολή στο ThingSpeak μόνο σε περίπτωση ανωμαλίας).

→ Ότι άλλο προτείνεται για την ολοκλήρωση της διπλωματικής και το προγραμματισμό τελικής συγγραφή της.