

Ανίχνευση Ανωμαλιών Θερμοκρασίας Εσωτερικού Χώρου μέσω IoT

Πειραματική Τεκμηρίωση & Μεθοδολογία Γενίκευσης

Κωστούλας Δημήτριος

1. Διερευνητική Ανάλυση Δεδομένων (Exploratory Data Analysis - EDA)

Περιγραφική Στατιστική (feeds.csv)


Metric	Indoor (f1)	Outdoor (f2)
Mean	23.12 °C	20.64 °C
Std Dev	1.23	2.63
Min	19.74 °C	15.41 °C
Max	25.84 °C	24.53 °C

Insulation Effect

Παρατηρούμε ότι η εσωτερική θερμοκρασία είναι εξαιρετικά σταθερή (Std 1.23 °C) παρά τις μεγάλες εξωτερικές διακυμάνσεις ημέρας/νύχτας.

Αυτό το "στατικό χάσμα" είναι η πρόκληση που πρέπει να αγνοήσει ο αλγόριθμος.

Visualisation: The Insulation Effect



| 2. Ορισμός Ανωμαλίας

Πρόελευση & Χαρακτηριστικά

Hardware : Arduino MKR Wifi 1010 Opla IoT Kit.

Indoor : Αισθητήρας HTS221 (Υγρασία / Θερμοκρασία).

Outdoor : Δεδομένα μέσω OpenWeather API.

Δειγματοληψία : Raw (1 min) → Resampled (10 min).

Dataset: 4,072 records (1min)

Resampled : 429 records (10 min mean)

Στο 10-λεπτο resampling επιλέχθηκε για βέλτιστη κατανάλωση ενέργειας (93% λιγότερες συνολικές μεταδόσεις (CPU cycles/sensor wake-ups). Κατά την τελική υλοποίηση στο Edge, μετάδοση (Wi-Fi) θα γίνεται μόνο όταν εντοπίζεται ανωμαλία, ελαχιστοποιώντας το transmission cost.)

Πρόελευση Δεδομένων: Μετρήσεις από δωμάτιο κατοικίας.


field1 = Εσωτερική θερμοκρασία δωματίου

field2 = Εξωτερική θερμοκρασία πόλης.

Τι ψάχνουμε; (True Positive)

- **Θερμικό Σοκ:** Απότομη πτώση που σπάει την αδράνεια.
- **Όχι Θόρυβο:** Μικρές διακυμάνσεις $\pm 0.1^{\circ}\text{C}$ φιλτράρονται στο resampling.

Στόχος: Εντοπισμός κρίσιμων ή απρόβλεπτων θερμικών γεγονότων (π.χ. ανθρώπινη παρέμβαση, βλάβη κλιματισμού, εκδήλωση πυρκαγιάς) που διαταράσσουν απότομα τη θερμική ισορροπία του δωματίου.



Zoom στη πτώση 1.3°C σε 10 λεπτά

3. Επιλογή Αλγορίθμου

Αλγόριθμος	Unsupervised	Edge OK	RAM Bias	Reference
Isolation Forest	✓ YES	✓ YES	Low	Liu et al. (2008)
LOF	✓ YES	✗ NO	High	Breunig et al. (2000)
Autoencoders	✓ YES	✗ NO	V. High	DL Architecture
Z-Score	✓ YES	✓ YES	Minimal	Statistical Baseline

Επιλέχθηκε το **Isolation Forest** λόγω της ικανότητας απομόνωσης ανωμαλιών χωρίς την ανάγκη αποθήκευσης ολόκληρης της κατανομής στη RAM(ώστε να μπορεί να μετατραπεί σε ένα σύνολο κανόνων ελέγχου (rule-based scorer / if-else) ιδανικό για το Arduino).

Τι σημαίνει πρακτικά Unsupervised: Ο αλγόριθμος εκπαιδεύεται βρίσκοντας μόνος του ποιο είναι το «φυσιολογικό» μοτίβο του σπιτιού, χωρίς να χρειάζεται να του έχουμε δώσει από πριν έτοιμα παραδείγματα (labels) του πώς μοιάζει ένα ανοιχτό παράθυρο. Αυτό είναι κρίσιμο, γιατί κάθε σπίτι έχει διαφορετική θερμική συμπεριφορά.

| 4. Δομή Μοντέλου: 5 Inputs



RoC 10m & 30m

Ρυθμός μεταβολής σε βραχυχρόνιο και μεσοπρόθεσμο ορίζοντα.



Rolling Std 30m

Μετράει την "αστάθεια" (volatility) που προκαλεί η ροή αέρα.



Delta Thermal Gap

Ο ρυθμός μεταβολής της διαφοράς Εσωτερικής - Εξωτερικής θερμοκρασίας.



+ **Acceleration** (2η παράγωγος) για την έναρξη του συμβάντος.

Γιατί δεν δίνουμε απλά τη θερμοκρασία;

Το μοντέλο δεν πρέπει να νοιάζεται αν το δωμάτιο έχει 20°C ή 25°C (απόλυτες τιμές). Πρέπει να εκπαιδευτεί στο να αναγνωρίζει τη συμπεριφορά (πόσο γρήγορα αλλάζει και πόσο ασταθής είναι η θερμοκρασία).

5. Στρατηγική Scaling


Γιατί RobustScaler;

Σε προβλήματα anomaly detection, ο StandardScaler (Mean/Std) επηρεάζεται από τις ίδιες τις ανωμαλίες που ψάχνουμε.

$$z = (x - \text{median}) / \text{IQR}$$

Χρησιμοποιώντας **Median** και **IQR**, διατηρούμε το "σήμα" των ανωμαλιών άθικτο, κάνοντάς τες να ξεχωρίζουν (Spikes > 3).

Οι παράμετροι του RobustScaler (Median, IQR) υπολογίζονται και "κλειδώνουν" αποκλειστικά στο Train Set για την αποφυγή Data Leakage.



| 6. Μεθοδολογία Γενίκευσης

70/30

Train / Test Split

Αποφυγή Overfitting

Το μοντέλο εκπαιδεύτηκε **μόνο** στο πρώτο 70% των δεδομένων.
(Χρονολογικό Train: 05/05 έως 07/05).

Το υπόλοιπο 30% ήταν εντελώς "άγνωστο" για τον αλγόριθμο.
(Χρονολογικό Test: 07/05 έως 08/05).

Διασφαλίζοντας ότι μπορεί να γενικεύσει σε μελλοντικά δεδομένα
(Unseen Data).

7. Case Study (Unseen)

Event: 08/05 07:10

Στο Test Set (μετά την κίτρινη γραμμή), ο αλγόριθμος εντόπισε επιτυχώς **7 ανωμαλίες**.

Score: -0.762

RoC: 0.93°C / 10 λεπτά.

Το μοντέλο έπιασε την ανωμαλία χωρίς να έχει δει ποτέ τη συγκεκριμένη μέρα.

Το μοντέλο αγνοεί τις φυσιολογικές διακυμάνσεις της νύχτας. Εντοπίζει με ακρίβεια τα **θερμικά σοκ** (κόκκινες κουκκίδες). Το Anomaly Score πέφτει κάτω από το threshold μόνο σε πραγματικά γεγονότα.



| 8. Ποσοτική Αξιολόγηση

+117%

" (0.280 - 0.129) / 0.129 = +117% "

Improvement

Score Separation Metric

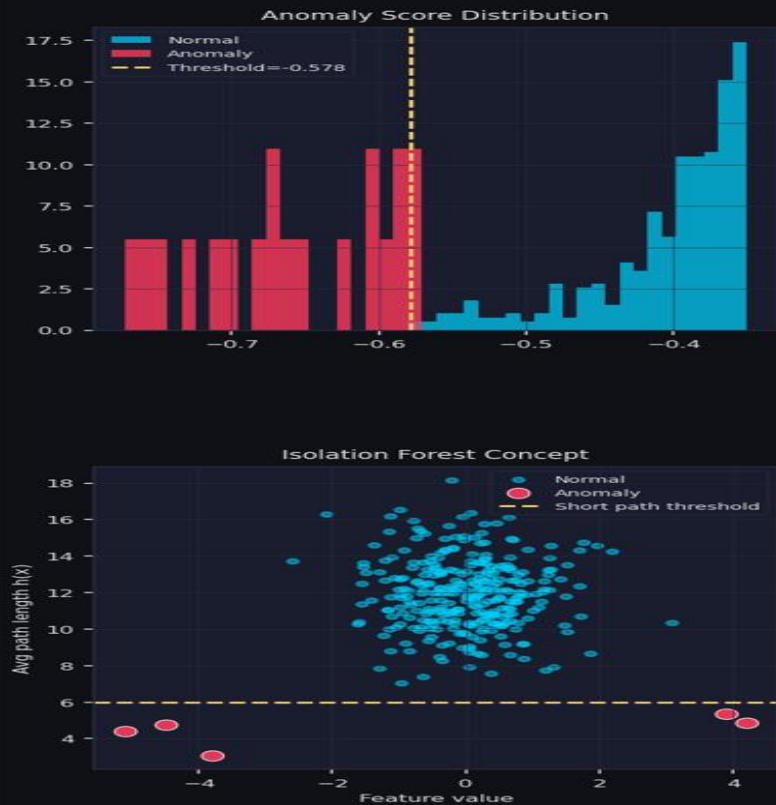
Απόσταση μέσου όρου Normal vs Anomaly:

· Raw Data: **0.129**

· Feature Engineering: **0.280**

Η χρήση των 5 features υπερδιπλασίασε την ικανότητα διαχωρισμού του μοντέλου.

9. Μαθηματική Θεμελίωση A



Path Length Logic

Το Isolation Forest απομονώνει σημεία σε δέντρα. Οι ανωμαλίες έχουν **μικρότερο μέσο βάθος** διαδρομής (Short Path Length).

Όσο πιο εύκολα απομονώνεται ένα σημείο, τόσο πιο ακραίο (anomalous) είναι.

Οι φυσιολογικές μετρήσεις (π.χ. σταθερά 22-23°C) είναι "στριμωγμένες" όλες μαζί, οπότε το δέντρο χρειάζεται πολλά splits (if-else) για να τις διαχωρίσει. Ένα θερμικό σοκ ωστόσο είναι μια "ξεκάρφωτη" τιμή στον χώρο. Ο αλγόριθμος την απομονώνει αμέσως με 1-2 τυχαία κοψίματα (Short Path Length), και έτσι καταλαβαίνει ότι είναι ανωμαλία.

9. Μαθηματική Θεμελίωση B


Signal Strength Analysis

Ποιο feature "φέρει" την ανωμαλία;

· **Rolling Std:** 7.16x απόκλιση.

· **Acceleration:** 6.19x απόκλιση.

Αυτά τα χαρακτηριστικά είναι οι πιο αξιόπιστοι δείκτες ανωμαλίας.



Ερωτήσεις;

GitHub: [Mitsakws/IoT-Edge-Anomaly-Detection](#)
